Informe Prueba Tecnica 1

Luis David Hernández

2026-03-04

Análisis descriptivo y exploratorio de los datos.

Primeramente cargamos los datos y verificamos las estructura de cada dataset (X,Y y Z), cada conjunto de datos corresponde a un histórico del comportamiento del precio diario de cada materia prima.

```
# Cargue de los datos

X <- read.csv("Datos/X.csv")
Y <- read.csv2("Datos/Y.csv", stringsAsFactors = F)
Z <- read.csv("Datos/Z.csv")
```

```
# dimensiones del conjunto de datos
dim(X);dim(Y);dim(Z)
```

```
[1] 9144    2
```

```
[1] 4485    2
```

```
[1] 3565    2
```

Observamos que cada dataset se compone de dos variables que son Date (Fecha) y Price (Precio), ademas el conjunto de datos X cuenta con 9144 registros, el conjunto de datos Y de 4485 registros y Z de 3565 registros.

Ahora verifiquemos el rango de la variable Date (Fecha) para conjunto de datos, pero primero adecuamos el formato fecha (Año-mes-dia) para la variable Date y organizamos las fechas.

Table 1: Rango de fechas de los conjuntos de datos

Conjunto de datos	Fecha inicial	Fecha Final
X	1988-06-27	2024-04-04
Y	2006-07-11	2023-09-12
Z	2010-01-01	2023-08-31

De la tabla Table 1 vemos que la materia prima X el rango de fechas es mayor en comparación con las materias primas Y y Z.

Ahora visualicemos como es el comportamiento del precio de cada materia prima.

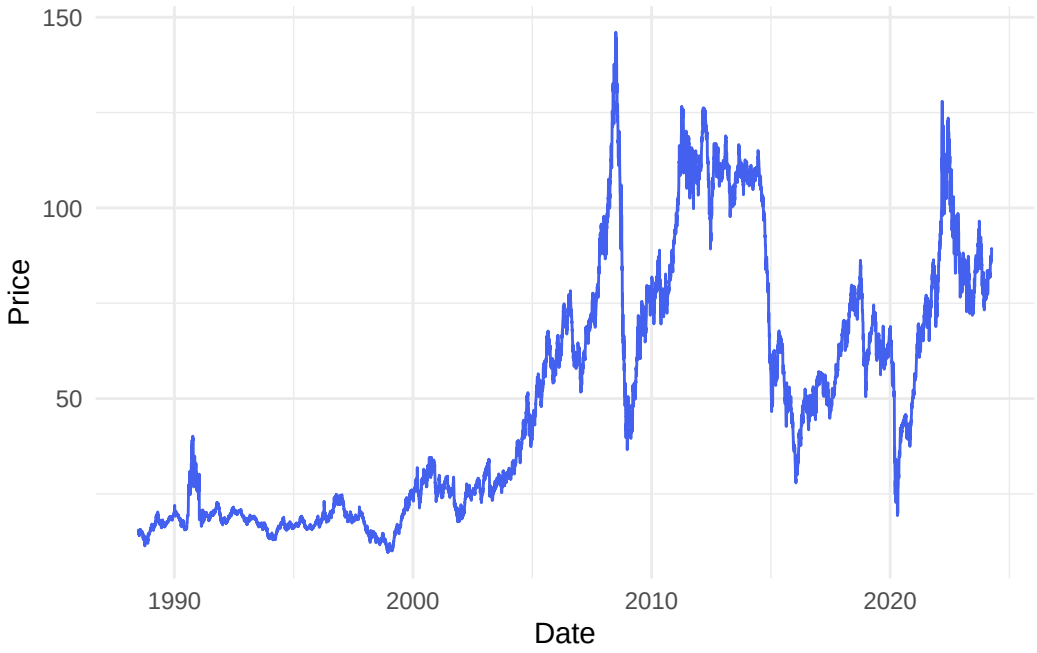

Figure 1: Evolución del precio de la materia prima X

En la Figure 1 se observa una tendencia creciente a medida que avanzan los años. Asimismo, se identifican fluctuaciones en el precio, con caídas y aumentos pronunciados. Estas variaciones podrían sugerir la influencia de factores externos sobre la serie, lo que en el contexto del análisis de series de tiempo se conoce como intervención.

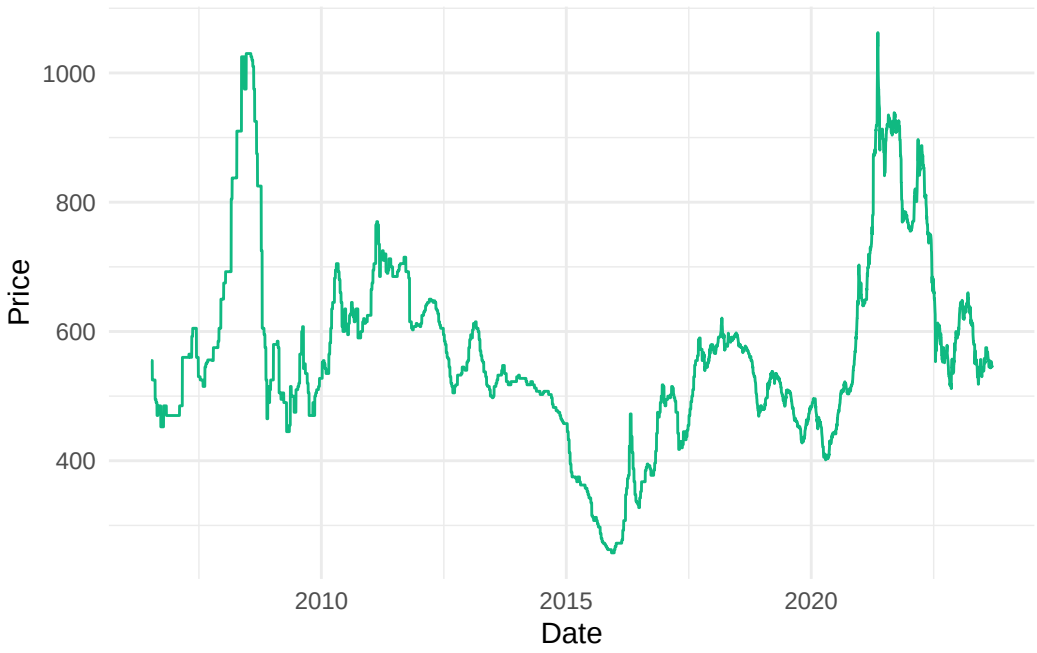

Figure 2: Evolución del precio de la materia prima X

En la Figure 2 se evidencian fluctuaciones a lo largo del tiempo, caracterizadas por aumentos y disminuciones en los valores de la serie. No obstante, no se observan tendencias persistentes ni comportamientos estacionales claramente definidos.

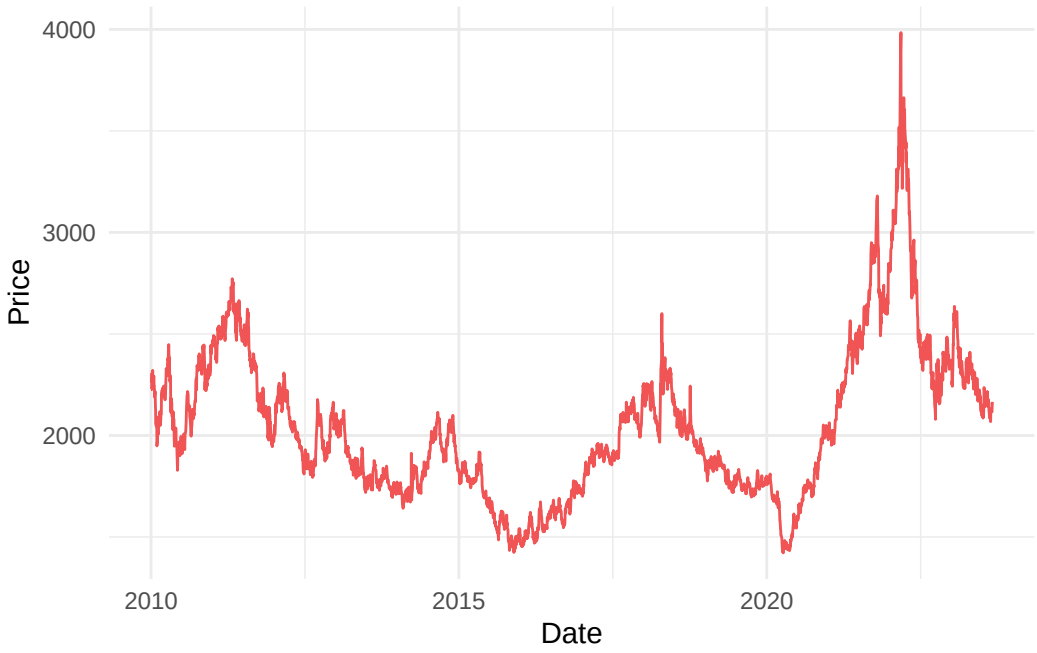

Figure 3: Evolución del precio de la materia prima Z

En la Figure 3 se observa cierto comportamiento estacional antes del año 2020. Posteriormente, a partir de 2020, la serie muestra una tendencia creciente, seguida de una caída en los precios.

Analisis descriptivos de las series

Calculamos algunos estadísticos muéstrales para cada una de las series.

Conjunto de datos	min	mean	sd	max
X	9.54	51.32	33.99	146.08
Y	257.5	543.7	145.15	1062.4
Z	1422	2037	372.98	3984

Observamos que el rango de precios de la materia prima X es menor en comparación con las demás materias primas, lo cual podría tener cierta influencia en la estimación del costo de los equipos.

Ahora veamos el comportamiento promedio de los precios de cada materia prima por mes.

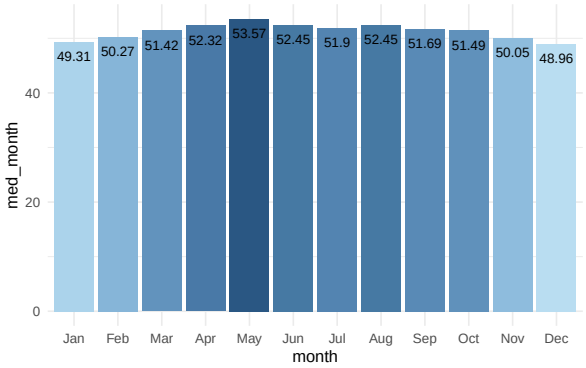

(a) X

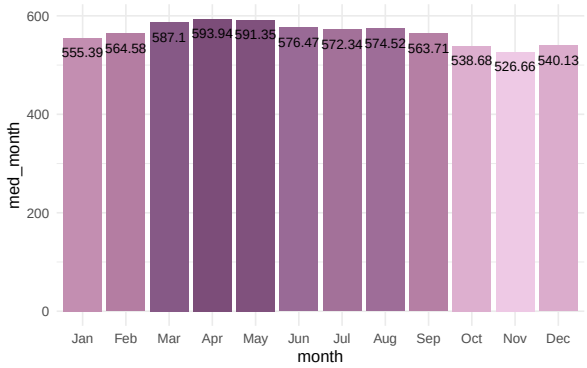

(b) Y

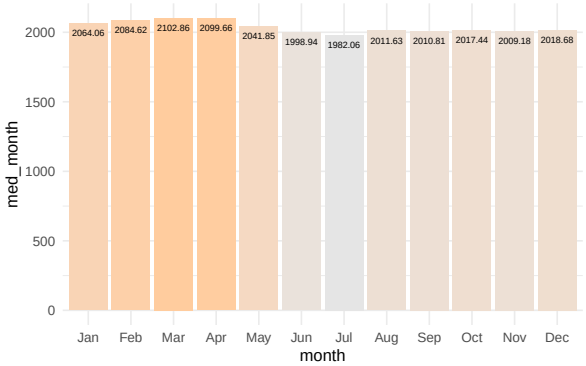

(c) Z

Figure 4: Precio promedio por mes

En la Figure 4 se aprecia que el precio promedio mensual por material es similar entre los distintos meses, lo que indicaría ausencia de un patrón estacional marcado en el promedio de precios.

Explicación del caso

Tenemos que una empresa constructora necesita estimar el costo de dos equipos esenciales para un proyecto de 36 meses. Los precios de estos equipos dependen de los costos de las materias primas que los componen:

- **Equipo 1**: 20% materia prima X y 80% materia prima Y.
- **Equipo 2**: partes iguales de X, Y y Z.

El objetivo es pronosticar los precios de las materias primas durante los próximos 36 meses y, a partir de ellos, calcular el costo de cada equipo. Esto permitirá una mejor planificación financiera y la optimización en la selección de proveedores.

Supuestos

Para desarrollar la estimación y proyección de los costos de los equipos, se establecieron los siguientes supuestos:

- Se dispone de datos históricos mensuales de los precios de X, Y y Z reflejando un comportamiento real del mercado.
- No existen errores sistemáticos de medición en los datos.
- Los datos diarios son suficientemente representativos para modelar tendencias y volatilidad.
- No se consideran factores externos como crisis económicas o cambios regulatorios; el modelo se basa únicamente en el comportamiento histórico.

Los costos de los equipos se calculan como combinaciones lineales de los precios de las materias primas.

Formas para resolver el caso

El proyecto tiene una duración de 36 meses, mientras que la información disponible de las materias primas X, Y y Z se encuentra en frecuencia diaria. Por tanto, antes de modelar, se evaluaron alternativas considerando: (i) alineación con el horizonte de planeación, (ii) estabilidad de las series y (iii) capacidad de cuantificar incertidumbre/riesgo en los costos.

Se evaluaron dos enfoques: modelar las materias primas individualmente o modelar directamente los costos históricos de los equipos. Dado que el objetivo del negocio es estimar el costo final del equipo y no el comportamiento individual de cada insumo, se optó por modelar cada serie (X, Y, Z) de forma independiente para pronosticar 36 meses, y luego se calcula el costo de cada equipo combinando los pronósticos.

Dado que el proyecto tiene horizonte de 36 meses y los costos se planifican presupuestalmente en cortes mensuales, se decidió transformar las series diarias en precios promedio mensuales, con el fin de reducir volatilidad de alta frecuencia y alinear el análisis con la frecuencia de decisión financiera.

Resultados del análisis de los datos y los modelos.

Primeramente calcularemos los promedios mensuales, visualizamos las nuevas series y luego procederemos modelaremos cada serie.

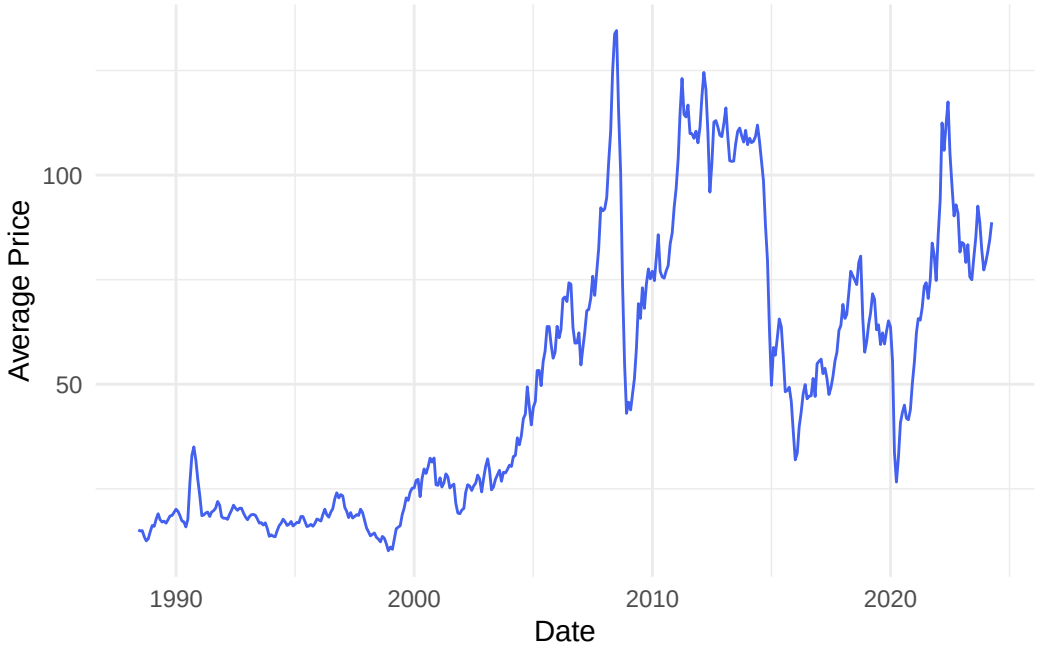

Figure 5: Serie de tiempo del precio promedio mensual de X

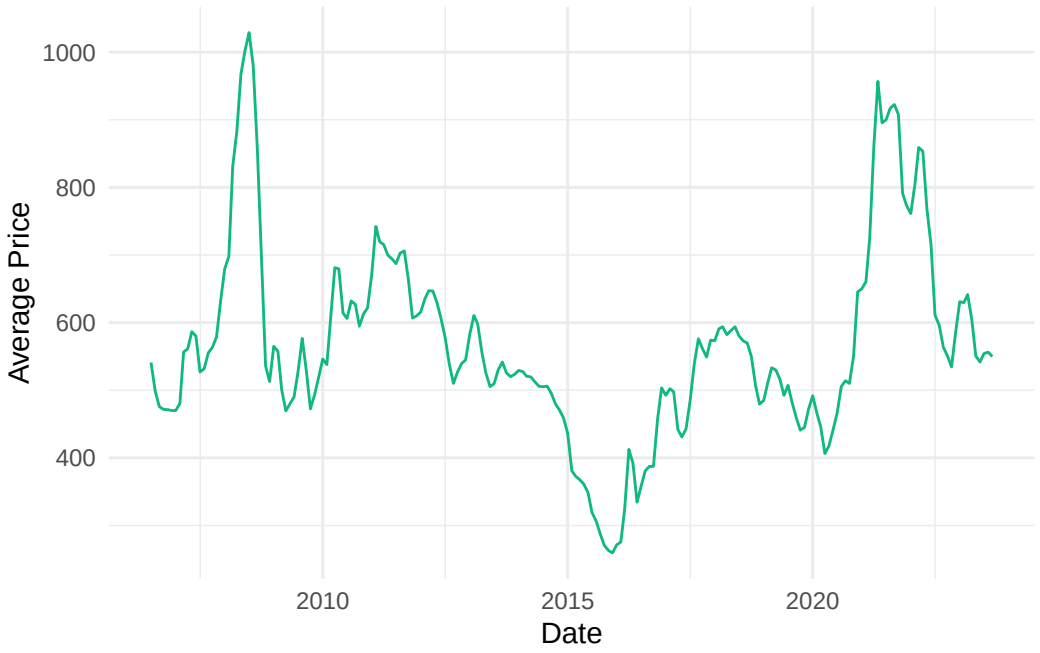

Figure 6: Serie de tiempo delprecio promedio mensual de Y

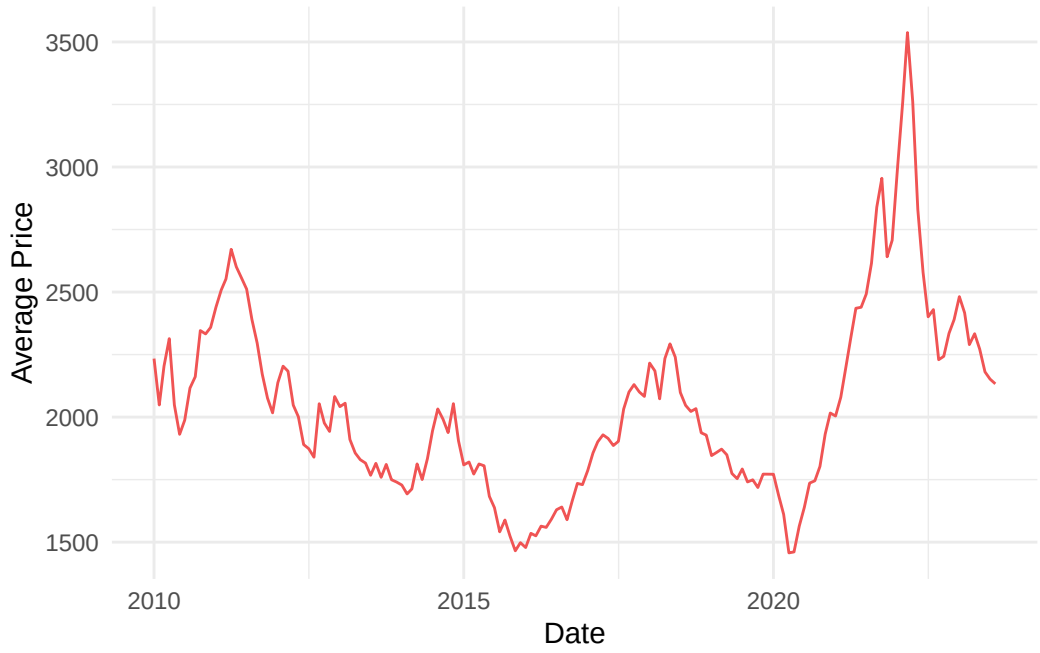

Figure 7: Serie de tiempo del precio promedio mensual de Z

En las Figure 5, Figure 6 y Figure 7 se evidencia que, al agregar la información a frecuencia mensual, las series de precios de cada materia prima preservan el patrón general observado en las series diarias.

Para la selección del modelo existen criterios de selección de modelos que permiten seleccionar el "mejor" tales como: AIC, BIC, AICC, entre otros. Estos criterios se suelen utilizar con la base de datos (BD) completa y no evalúan como se comporta el modelo con respecto a los pronósticos.

El **backtesting** es un método de validación en series de tiempo utilizado para comparar los pronósticos que realiza un modelo versus los valores reales. Para ver el funcionamiento de este método definimos algunas medidas de precisión:

- **Media Del Error Absoluto** (MAE):

$$MAE = \sum_{t=1}^{m} \frac{|X_t - \hat{X}_t|}{m}$$

- **Media Cuadrática del Error** (MSE):

$$MSE = \sum_{t=1}^{m} \frac{(X_t - \hat{X}_t)^2}{m}$$

- **Media del error porcentual absoluto** (MAPE):

$$MAPE = 100 * \frac{1}{m} \sum_{t=1}^{m} \frac{|X_t - \hat{X}_t|}{|X_t|}$$

El método más simple de validación consiste en particionar la serie en solo dos conjuntos de datos: Entrenamiento (Train) y Prueba (Test):

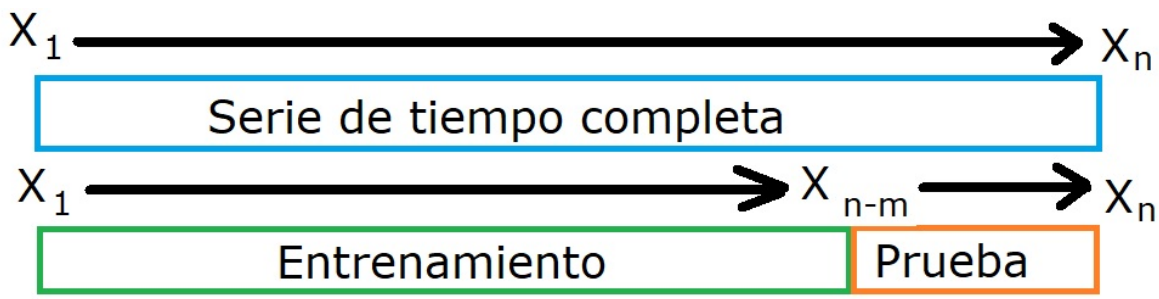

Como el objetivo del proyecto es pronosticar los precios de las materias primas durante los próximos 36 meses y, a partir de ellos, calcular el costo de cada equipo dejaremos para prueba los últimos 36 meses de cada serie. Compararemos dos modelos para cada una de las series, que serán un modelos ARIMA/SARIMA encontrado con la función `auto.arima()` y un modelo de Holt-Winters.

El modelo **SARIMA** (Seasonal AutoRegressive Integrated Moving Average) es una extensión del modelo **ARIMA** que permite modelar series de tiempo que presentan **estacionalidad** (patrones que se repiten cada cierto número fijo de periodos). Se denota como:

$$SARIMA(p, d, q)(P, D, Q)_s$$

donde:

- (p, d, q) son los órdenes de la parte **no estacional** (ARIMA).
- (P, D, Q) son los órdenes de la parte **estacional**.
- s es el **periodo estacional** (por ejemplo $s = 12$ en datos mensuales con ciclo anual).

EL modelo se compone de:

Parte no estacional (ARIMA)

- p **(AR)**: orden autoregresivo, dependencia con valores pasados.
- d **(I)**: número de diferencias para lograr estacionariedad.

- q **(MA)**: orden de media móvil, dependencia con errores pasados.

Parte estacional

- P **(AR estacional)**: dependencia con valores pasados separados por s periodos.
- D **(diferencia estacional)**: número de diferencias para remover estacionalidad.
- Q **(MA estacional)**: dependencia con errores pasados separados por s periodos.

Ejemplos típicos de s:

- $s = 12$: datos **mensuales** con estacionalidad anual.
- $s = 4$: datos **trimestrales**.
- $s = 7$: datos **diarios** con patrón semanal.

La forma general del modelo se expresa como:

$$\Phi_P(B^s)\,\phi_p(B)\,(1-B)^d(1-B^s)^D y_t = \Theta_Q(B^s)\,\theta_q(B)\,\varepsilon_t$$

donde:

- ε_t es un término de error (idealmente **ruido blanco**).
- $\phi_p(B)$ es el polinomio AR no estacional.
- $\theta_q(B)$ es el polinomio MA no estacional.
- $\Phi_P(B^s)$ es el polinomio AR estacional.
- $\Theta_Q(B^s)$ es el polinomio MA estacional.

El método **Holt-Winters** parte del método Holt que se basa en estimar el nivel mas reciente y la tendencia mediante el uso de dos parámetros de suavizamiento de α y β. Si detonamos por L_n al valor del nivel mas reciente, se usa el pronostico de la serie en el instante $n + h$ como:

$$\hat{X}_{n+h} = L_n + hT_n$$

Los cálculos para los valores más recientes de los niveles y la tendencia se obtienen con las ecuaciones:

$$\begin{aligned} L_n &= \alpha X_n + (1-\alpha)\,(L_{n-1} + T_{n-1}) \\ T_n &= \beta\,(L_n - L_{n-1}) + (1-\beta)T_{n-1} \end{aligned}$$

Dado un conjunto de entrenamiento el método de Holt consiste en encontrar el α y el β que minimicen la suma cuadrática del error.

Ahora el método de Holt-Winters es una extensión del método de Holt y se plantea como:

$$\hat{X}_{n+h} = L_n + hT_n + S_{n+h+k}$$

donde:

$$\begin{aligned} L_n &= \alpha(X_n - S_{n-k}) + (1-\alpha)(L_{n-1} + T_{n-1}) \\ T_n &= \beta(L_n - L_{n-1}) + (1-\beta)T_{n-1} \\ S_n &= \gamma(X_n - L_n) + (1-\gamma)S_{n-k} \end{aligned}$$

Entonces dado un conjunto de entrenamiento el método de Holt-Winters consiste en encontrar el α, β y γ que minimicen la suma cuadrática del error.

Ajustes de los modelos ARIMA.

Al ajustar los modelos ARIMA sobre el conjunto de entrenamiento de las series mensuales de X, Y y Z, se obtienen los siguientes resultados:

Table 3: Resultados métricas del conjunto de entrenamiento para los modelos ARIMA/SARIMA

Conjunto de entrenamiento	Modelo Arima	RMSE	MAE	MAPE
X	$SARIMA(2,1,1)x(0,0,2)_{12}$	4.059876	2.784667	6.241398
Y	$ARIMA(1,1,3)$	30.00695	21.84923	4.134125
Z	$SARIMA(0,1,1)x(2,0,0)_{12}$	76.29784	59.70664	3.07803

Ajustes de los modelos Holt-Winters.

Ahora ajustaremos los modelos de Holt-Winters sobre el conjunto de entrenamiento de las series mensuales X, Y y Z, se obtienen los siguientes resultados:

Table 4: Resultados métricas del conjunto de entrenamiento para modelos Holt-Winters

Conjunto de entrenamiento	Modelo Holt-Winters	RMSE	MAE	MAPE
X	$\alpha = 1, \beta = 0, \gamma = 0$	4.715085	3.11396	7.14340
Y	$\alpha = 0.9454418, \beta = 0.02261245656, \gamma = 1$	44.99005	44.99005	6.225801
Z	$\alpha = 0.7752859, \beta = 0.02207936, \gamma = 1$	111.7206	86.34354	4.538181

A partir del análisis de las tablas Table 3 y Table 4, se opta por los modelos ARIMA, dado que presentan mejores métricas de desempeño frente a los modelos Holt-Winters. En consecuencia, se procede a ajustar estos modelos utilizando la base de datos completa y a generar pronósticos a 36 meses, junto con sus respectivas visualizaciones.

```
Series: serie_tsx
ARIMA(2,1,1)

Coefficients:
         ar1      ar2      ma1
      1.3062  -0.3894  -0.9294
s.e.  0.0715   0.0446   0.0644

sigma^2 = 19.26:  log likelihood = -1244.74
AIC=2497.49   AICc=2497.58   BIC=2513.74
```

```
Series: serie_tsy
ARIMA(1,0,2)(2,0,0)[12] with non-zero mean
```

```
Coefficients:
         ar1     ma1     ma2    sar1     sar2      mean
      0.9060  0.6360  0.2056  0.0173  -0.0034  564.7977
s.e.  0.0308  0.0715  0.0774  0.0712   0.0776   43.7216

sigma^2 = 1135:  log likelihood = -1020.33
AIC=2054.66   AICc=2055.23   BIC=2077.99
```

```
Series: serie_tsz
ARIMA(2,1,2)(2,0,0)[12]

Coefficients:
         ar1      ar2      ma1     ma2     sar1     sar2
      0.4382  -0.7839  -0.1796  0.7317  -0.1931  -0.3302
s.e.  0.1254   0.1294   0.1206  0.1694   0.0948   0.0984

sigma^2 = 9022:  log likelihood = -972.32
AIC=1958.64   AICc=1959.36   BIC=1980.29
```

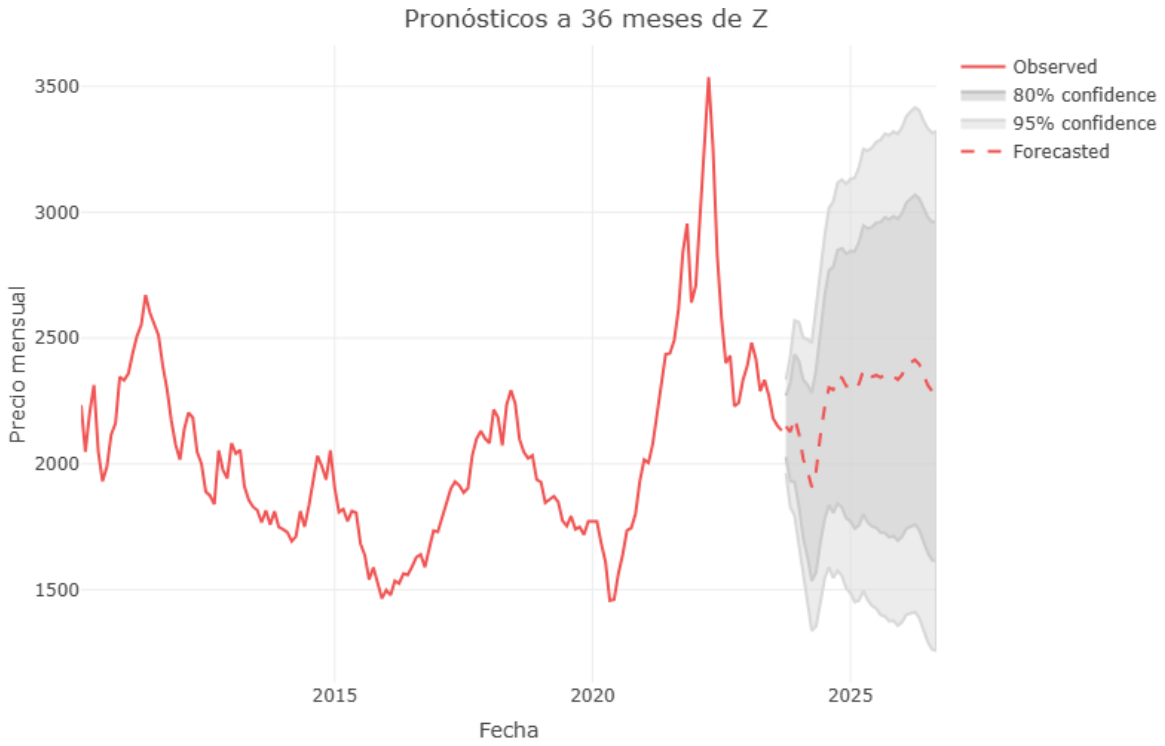

Con los pronósticos a 36 meses de cada materia prima, se procede a estimar el costo de cada equipo. En particular, el cálculo de los costos se realiza de la siguiente forma:

$$\hat{C}_1 = 0.2\hat{X}_{h=36} + 0.8\hat{Y}_{h=36}$$
$$\hat{C}_2 = 0.2\hat{X}_{h=36} + 0.8\hat{X}_{h=36}$$

Donde:

- C_i costo para el equipo i con $i = 1, 2$.
- $X_{h=36}$ pronósticos a 36 meses para la materia prima X.
- $Y_{h=36}$ pronósticos a 36 meses para la materia prima Y.
- $Z_{h=36}$ pronósticos a 36 meses para la materia prima Z.

Table 5: Estimación esperada de los costos mensuales para cada equipo C_1 y C_2

Mes	C_1	C_2
1	455.8031	928.6694
2	456.5468	921.9664
3	458.4261	940.8683
4	460.0836	921.0340
5	460.8307	887.7499
6	461.6428	872.1460
7	461.8679	850.8228
8	462.0024	871.5032
9	462.6210	919.3907
10	463.6150	956.9585
11	464.1748	983.1478
12	464.6224	980.4384
13	465.0278	997.6221
14	465.4553	996.6331
15	465.6912	985.7622
16	465.9045	985.7288
17	466.2015	980.9534
18	466.4386	989.1488
19	466.7730	1007.4320
20	467.1305	1000.4384
21	467.3558	998.7986
22	467.5126	1000.6695
23	467.6744	997.8901
24	467.8422	1000.9513
25	467.9860	996.9281
26	468.1087	999.6665
27	468.2130	995.1571
28	468.3077	1001.5700
29	468.3979	1013.9617
30	468.4786	1018.1238
31	468.5556	1021.6193
32	468.6267	1015.7978
33	468.6877	1000.2947
34	468.7408	987.9413
35	468.7904	980.1297
36	468.8359	980.3997

Futuros ajustes o mejoras

Aun cuando el enfoque basado en ARIMA permite obtener pronósticos y rangos de incertidumbre para estimar los costos de los equipos, existen mejoras potenciales para aumentar la precisión, robustez y utilidad del análisis en un contexto real de planeación financiera de un proyecto de 36 meses:

- En esta prueba se modelaron las materias primas de manera independiente. En un escenario real, X, Y y Z pueden presentar co-movimientos y choques comunes. Una mejora natural es utilizar modelos multivariados como VAR/VARMAX, que capturan la dinámica conjunta y pueden producir escenarios más coherentes entre series, especialmente cuando la correlación entre insumos es alta.
- Los precios de materias primas suelen presentar heterocedasticidad (volatilidad cambiante). Una mejora es combinar ARIMA (media) con GARCH (varianza), lo cual puede producir intervalos de predicción más realistas y una cuantificación de riesgo más precisa, especialmente útil para presupuestos con tolerancia al riesgo o márgenes de contingencia.
- Aunque se hizo backtesting, para fortalecer la confiabilidad, se pueden aplicar otros esquemas de validación tipo rolling-origin (ventanas deslizantes), comparando ARIMA contra alternativas como, Prophet o modelos de ML para series (cuando aplique). La selección final puede basarse en métricas (RMSE/MAE/MAPE) y en estabilidad de los residuos.

Apreciaciones y comentarios

El presente ejercicio permite ilustrar cómo las técnicas de análisis de series de tiempo pueden apoyar procesos de planeación financiera en proyectos de construcción. A partir de información histórica de precios de materias primas, es posible construir modelos predictivos que permitan anticipar el comportamiento futuro de los costos de los equipos requeridos para la ejecución del proyecto.

Una de las principales ventajas del enfoque utilizado es que permite traducir la dinámica de mercado de los insumos en estimaciones cuantitativas del costo esperado de los equipos. Esto facilita la toma de decisiones relacionadas con presupuestación, selección de proveedores y evaluación de riesgos asociados a variaciones en los precios de materias primas.

No obstante, es importante reconocer que los modelos de series de tiempo se basan en el supuesto de que los patrones históricos continuarán en el futuro. En mercados de commodities (materias primas), factores externos como cambios macroeconómicos, conflictos geopolíticos, variaciones en la oferta global o cambios regulatorios pueden generar choques que no estén reflejados en el histórico utilizado para el entrenamiento del modelo.

Asimismo, el análisis presentado se centra únicamente en el costo asociado a las materias primas que componen los equipos. En un escenario real de planificación de proyectos sería conveniente complementar este análisis incorporando otros componentes del costo, como transporte, almacenamiento, tiempos de entrega, márgenes de proveedores o posibles variaciones en el tipo de cambio.

Finalmente, este tipo de ejercicios demuestra el valor que puede aportar la analítica de datos en procesos de toma de decisiones empresariales. Incluso modelos relativamente sencillos, como los modelos ARIMA utilizados en este caso, pueden proporcionar información valiosa sobre tendencias, incertidumbre y posibles escenarios futuros, contribuyendo a una mejor gestión del riesgo y a una planificación financiera más informada.